Cours 2 : Deep Learning pour les données séquentielles

François HU - 05/07/2021

Data Scientist au DataLab de la Société Générale Assurances

Doctorant à l'ENSAE-CREST

Les cours se trouvent ici : https://curiousml.github.io/

Sommaire

1. **Introduction**

2. **Recurrent Neural Network (RNN)**
   - Modèles RNN « classique »
   - D'autres architectures RNN
   - Modèle Bidirectional-RNN (BRNN)
   - Modèle Deep RNN

3. **OPTION**
   - [option] LSTM / GRU
   - [option] BERT

Programme

Introduction

Représentations vectorielles

Deep Learning pour NLP

Active Learning

Introduction

Pourquoi les modèles séquentiels ?

- classification de textes / analyse de sentiment
- Named Entity Recognition (NER)
- génération de textes / de musiques
- traducteur de langue automatique
- …

Pourquoi pas les réseaux de neurones « standard » ?

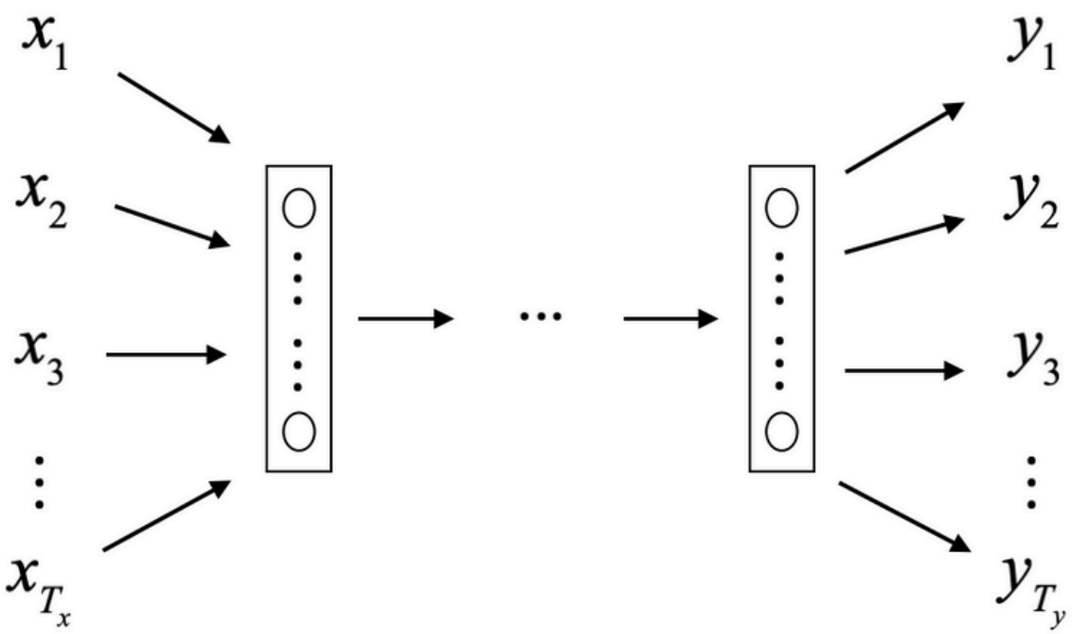

Introduction

Pourquoi les modèles séquentiels ?

- classification de textes / analyse de sentiment
- Named Entity Recognition (NER)
- génération de textes / de musiques
- traducteur de langue automatique
- …

Pourquoi pas les réseaux de neurones « standard » ?

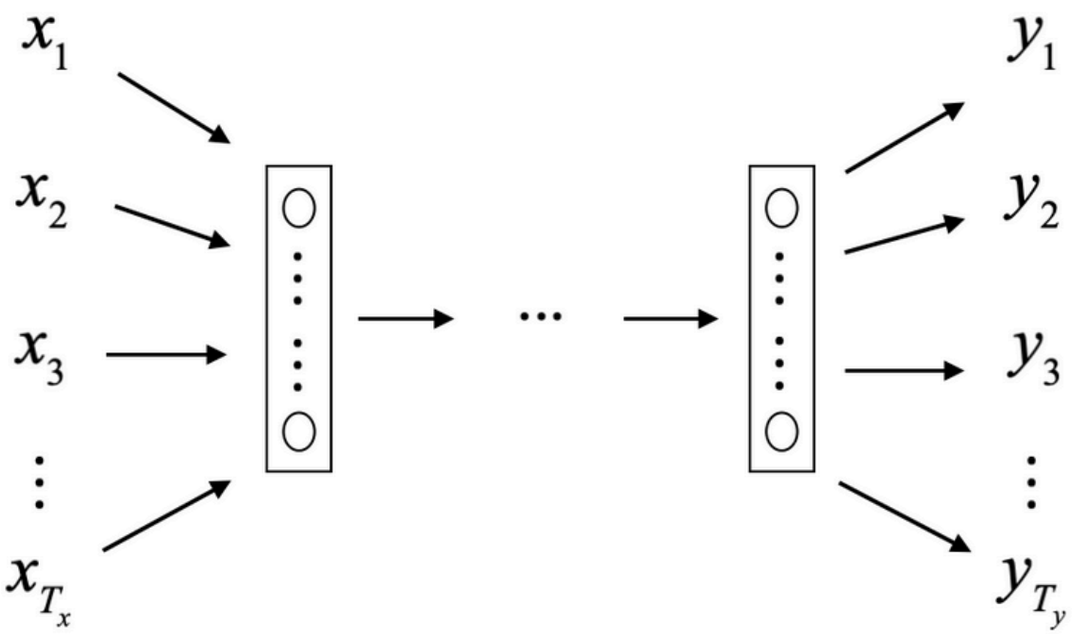

- inputs / outputs peuvent être de **tailles différentes**
- ne tient pas en compte des **différentes positions** des mots

2. Recurrent Neural Networks (RNN)

Modèle RNN « classique » (1/3)

Word embedding (plongement de mot en français) : vectorisation des mots de sorte que les mots apparaissant dans des contextes similaires ont des significations apparentées

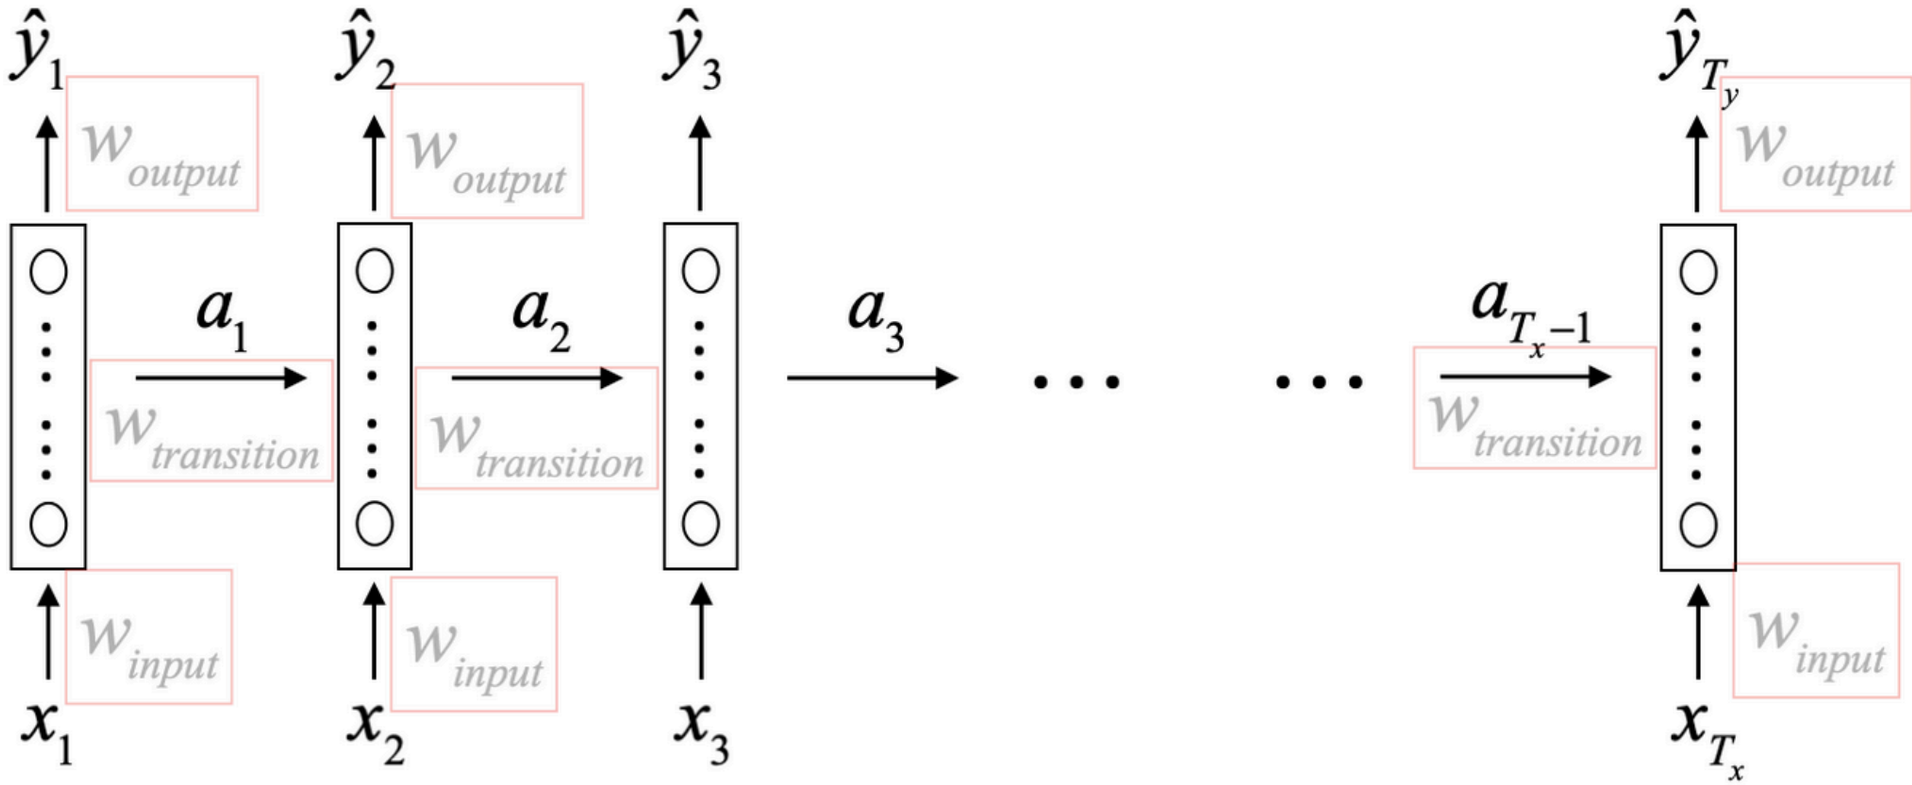

- possibilité de **manipuler des séquences** de taille variable
- tout calcul futur **tient compte des calculs passés**
- les poids / paramètres sont **partagés dans le temps**

Modèle RNN « classique » (2/3)

Propagation avant (forward propagation) d'un RNN :

Pour voir l'animation :
https://curiousml.github.io/teaching/DSA/RNNforward.html

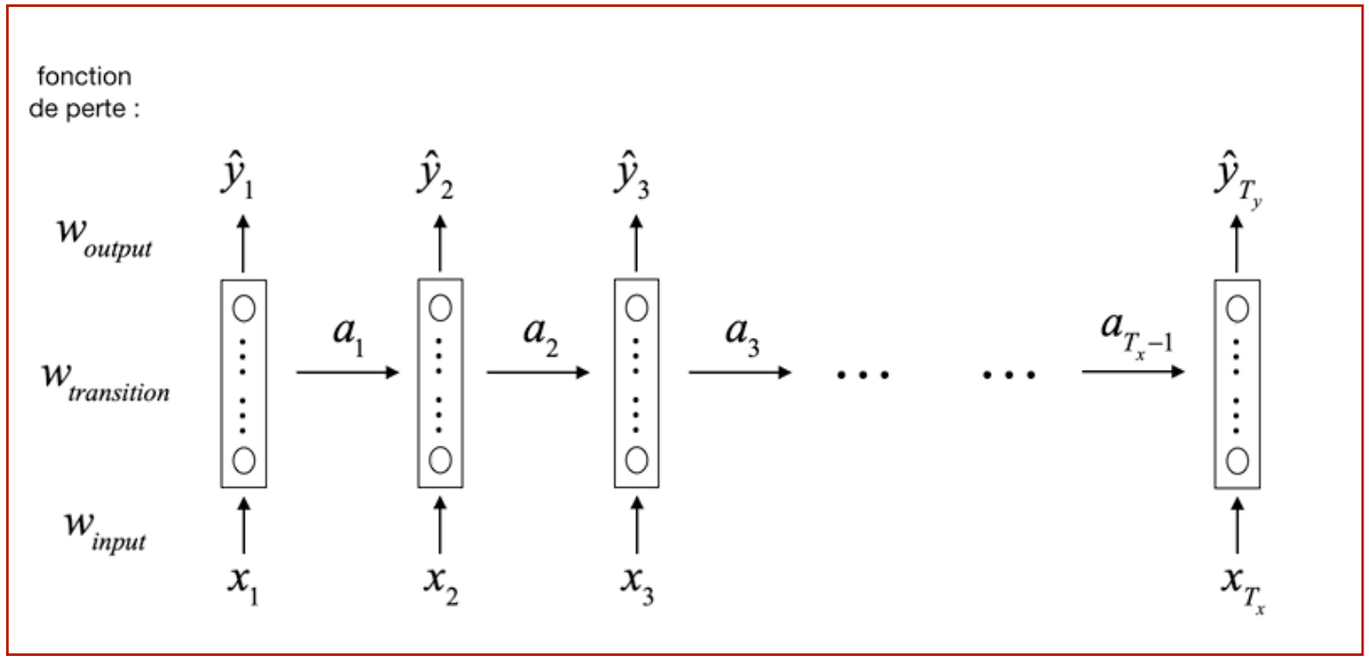

étant donné les poids w_{intput}, $w_{transition}$ et w_{output}, nous allons calculer a_t, $\hat{y}_t$ et $l_t = l(y_t, \hat{y}_t)$

Au temps t = 0 : $\boxed{a_0 = \vec{0}}$

Au temps t > 0 : $\boxed{\begin{aligned} a_t &= \sigma_{transition}(w_{transition} \cdot a_{t-1} + w_{input} \cdot x_t) \\ \hat{y}_t &= \sigma_{output}(w_{output} \cdot a_t) \end{aligned}}$

Modèle RNN « classique » (2/3)

Propagation avant (forward propagation) d'un RNN :

Pour voir l'animation :
https://curiousml.github.io/teaching/DSA/RNNforward.html

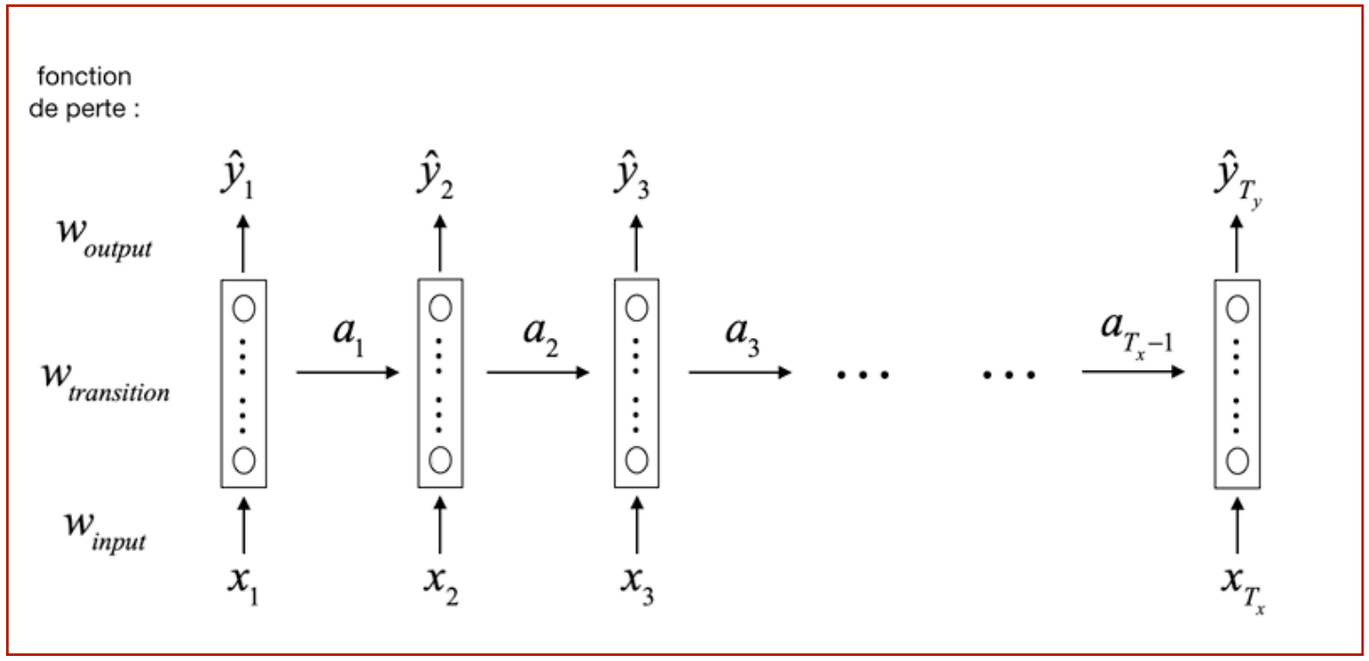

étant donné les poids w_{intput}, $w_{transition}$ et w_{output}, nous allons calculer a_t, $\hat{y}_t$ et $l_t = l(y_t, \hat{y}_t)$

Au temps t = 0 : $\boxed{a_0 = \vec{0}}$

Au temps t > 0 :

$$a_t = \sigma_{transition}(w_{transition} \cdot a_{t-1} + w_{input} \cdot x_t)$$

$$\hat{y}_t = \sigma_{output}(w_{output} \cdot a_t)$$

Exemple de **fonction de perte** : **Cross-Entropy**

Exemple de **fonction d'activation** :
$\sigma_{transition}$ ← tanh ou ReLu
σ_{output} ← sigmoid ou softmax

Modèle RNN « classique » (3/3)

Propagation arrière (back-propagation) d'un RNN :

Pour voir l'animation :
https://curiousml.github.io/teaching/DSA/RNNbackprop.html

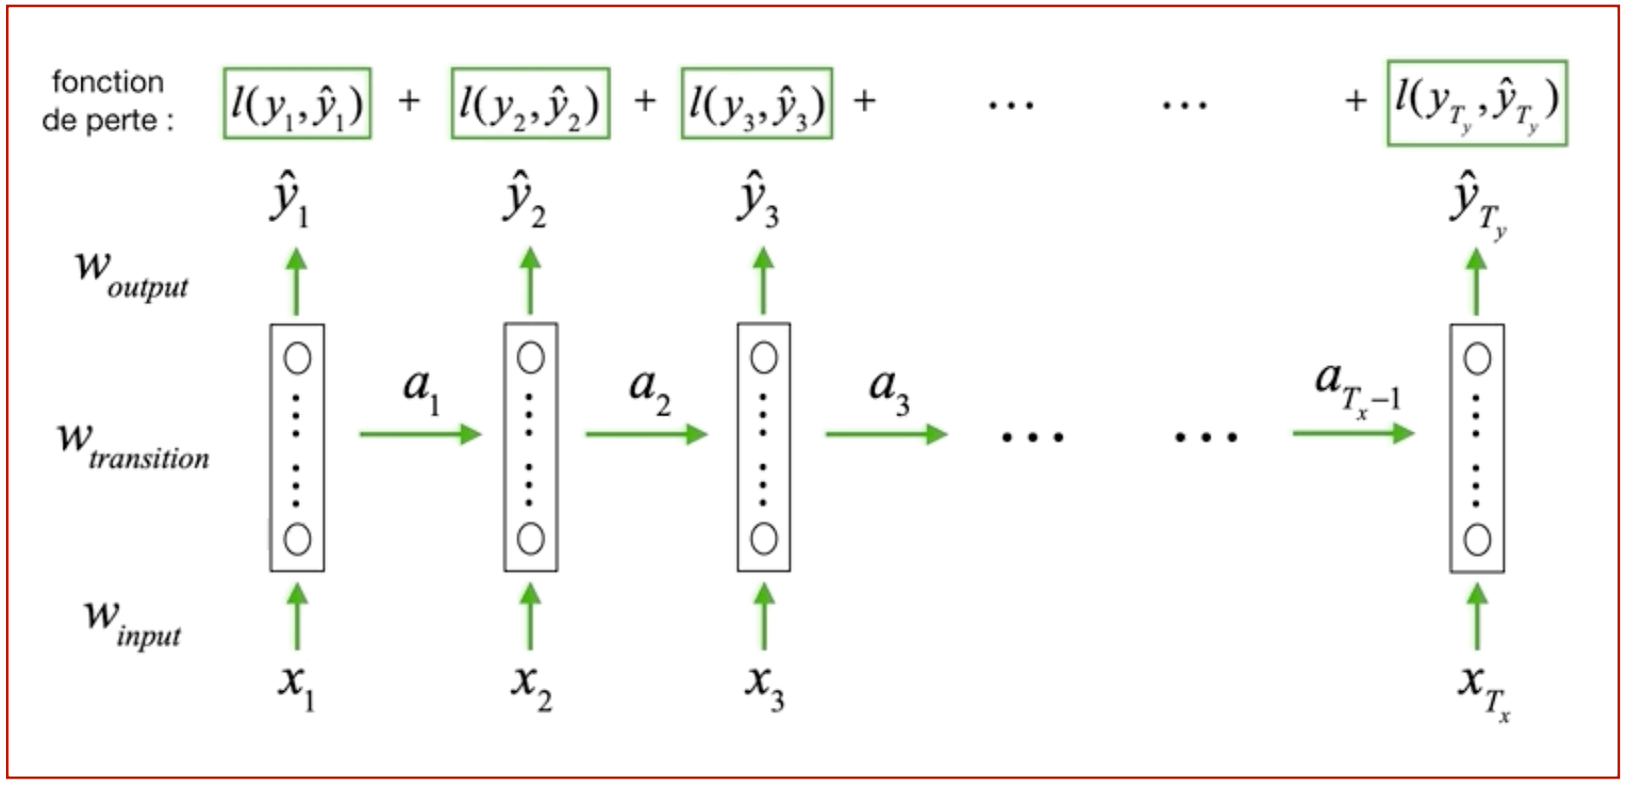

mettre à jour les poids w_{intput}, $w_{transition}$ et w_{output} afin de minimiser les fonctions de pertes $l_t = l(y_t, \hat{y}_t)$

Modèle RNN « classique » (3/3)

Propagation arrière (back-propagation) d'un RNN :

Pour voir l'animation :
https://curiousml.github.io/teaching/DSA/RNNbackprop.html

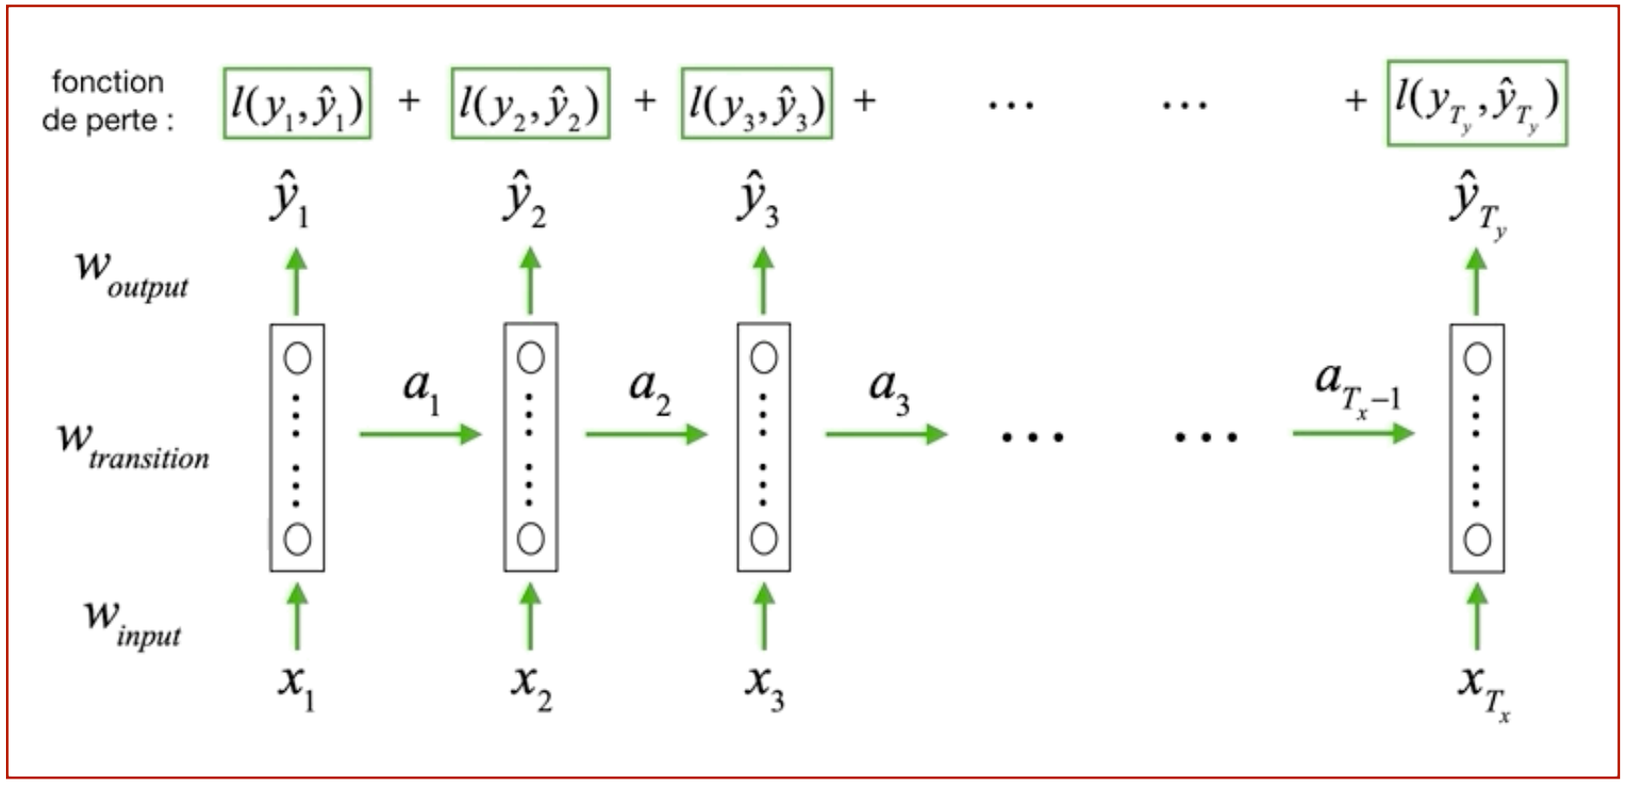

mettre à jour les poids w_{intput}, $w_{transition}$ et w_{output} afin de minimiser les fonctions de pertes $l_t = l(y_t, \hat{y}_t)$

Par descente de gradient

D’autres architectures RNN

Architecture N-N, N-1, 1-N, N-M

Architecture N-N

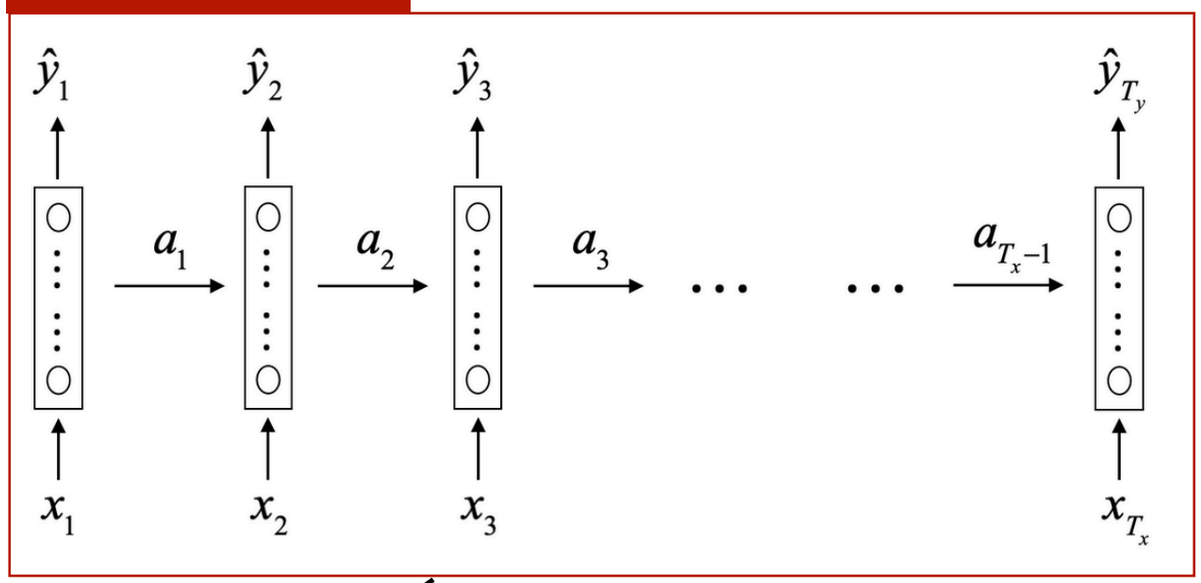

Named Entity Recognition (NER)

D’autres architectures RNN

Architecture N-N, N-1, 1-N, N-M

Architecture N-N

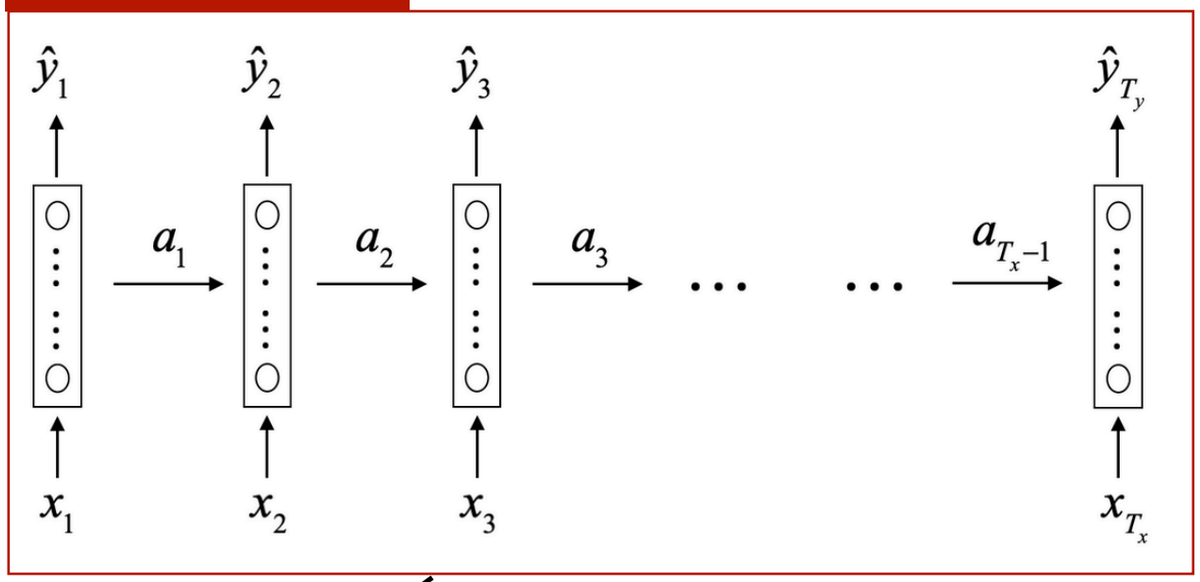

Named Entity Recognition (NER)

Architecture N-1

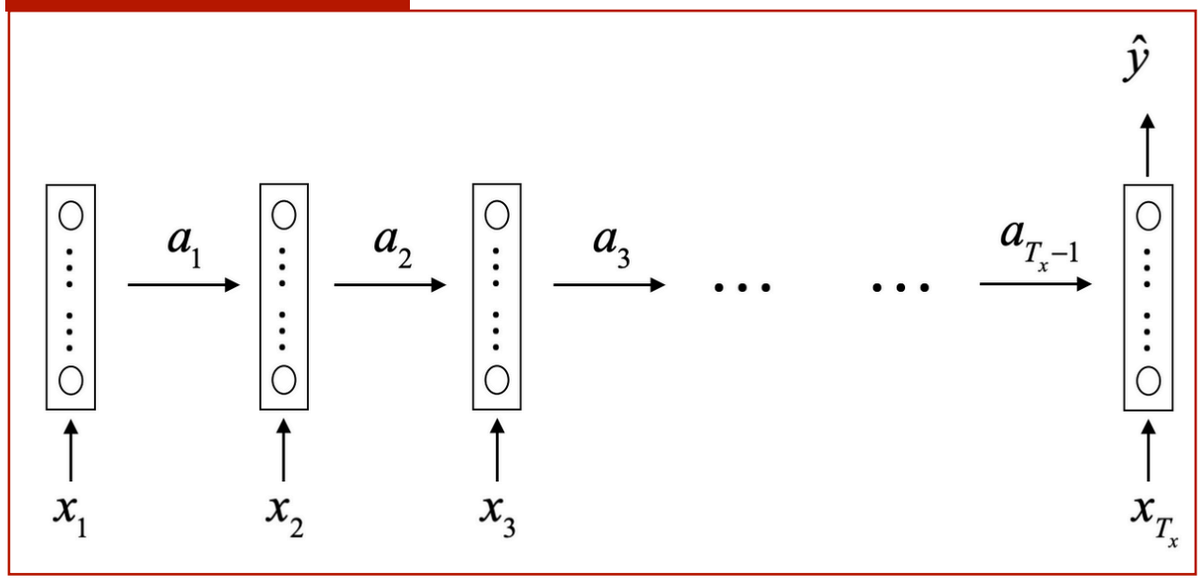

Classification de textes

D’autres architectures RNN

Architecture N-N, N-1, 1-N, N-M

Architecture N-N

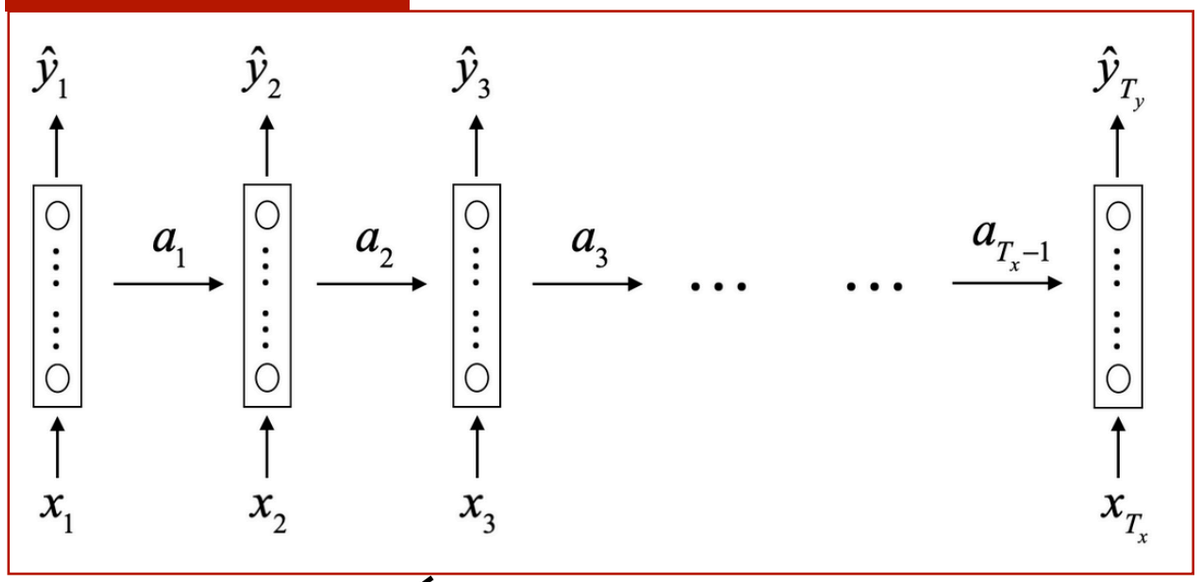

↳ Named Entity Recognition (NER)

Architecture N-1

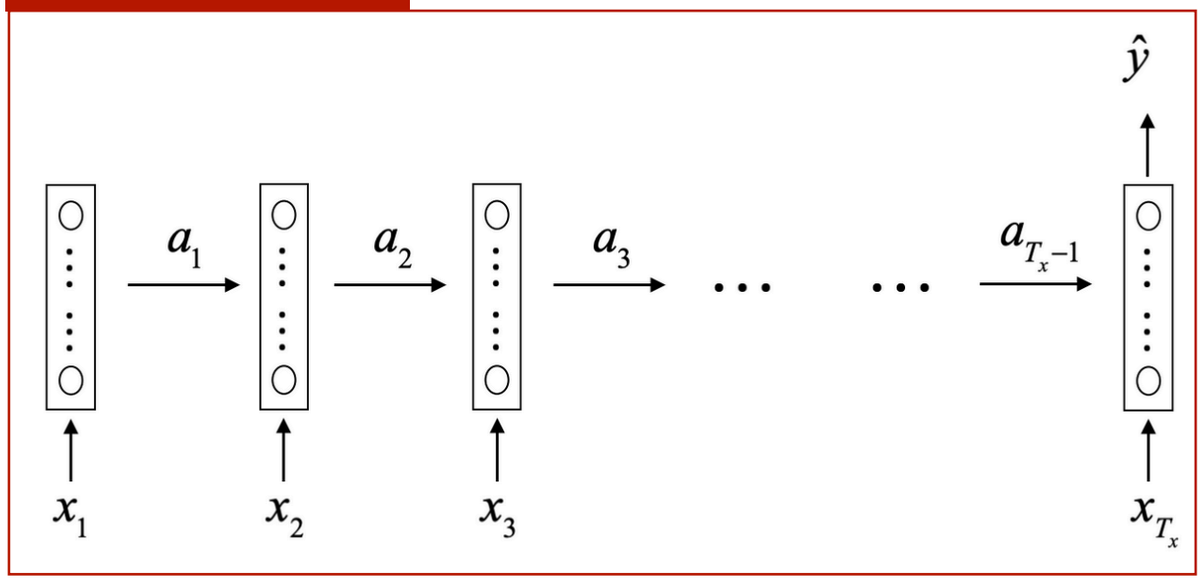

↳ Classification de textes

Architecture 1-N

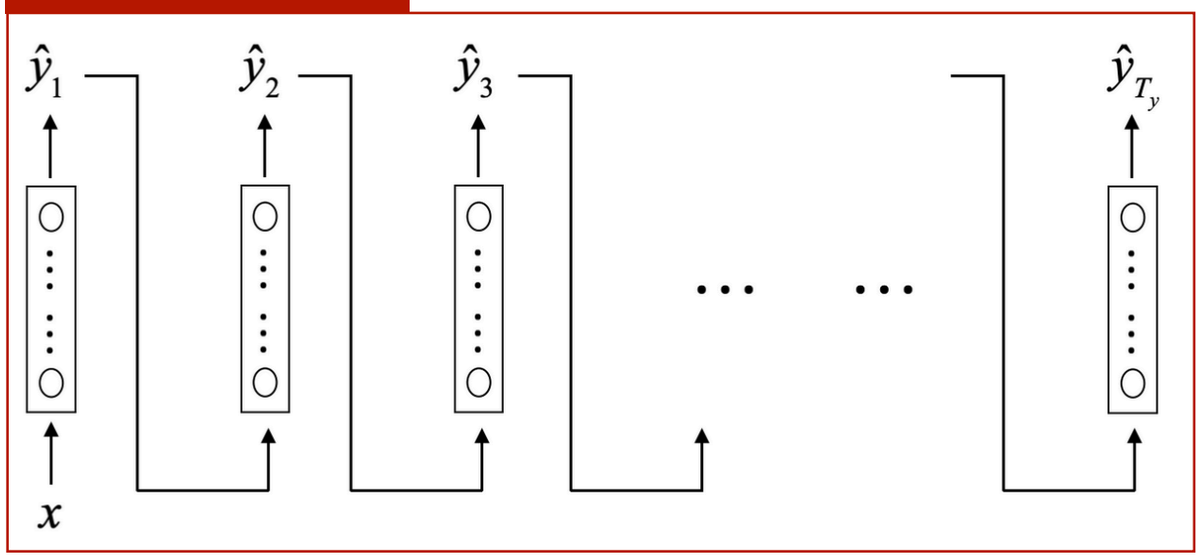

↳ Génération de séquences (textes, musique)

D’autres architectures RNN

Architecture N-N, N-1, 1-N, N-M

Architecture N-N

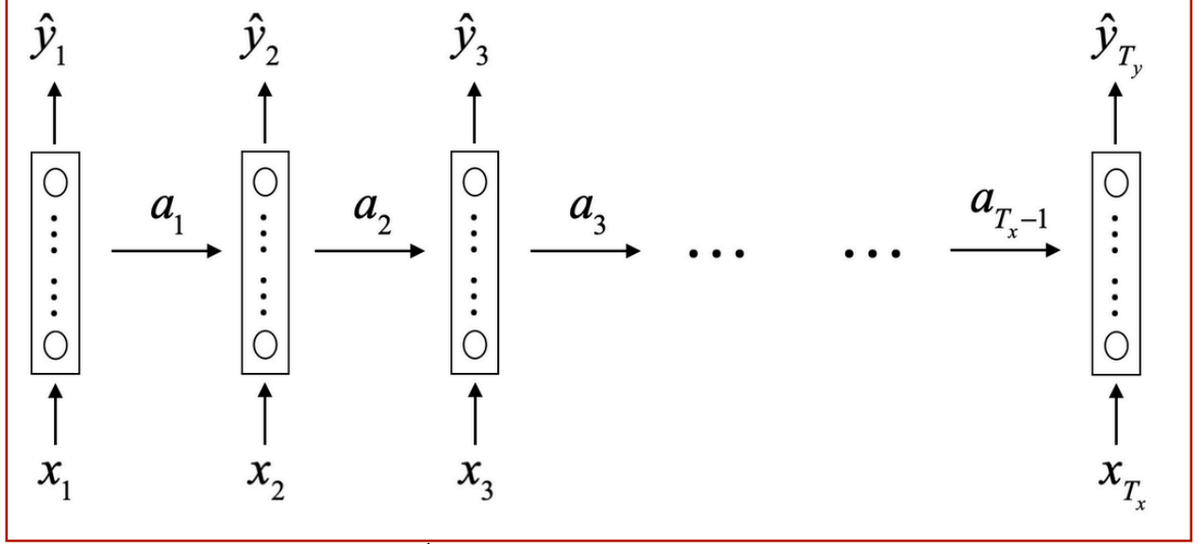

↳ Named Entity Recognition (NER)

Architecture N-1

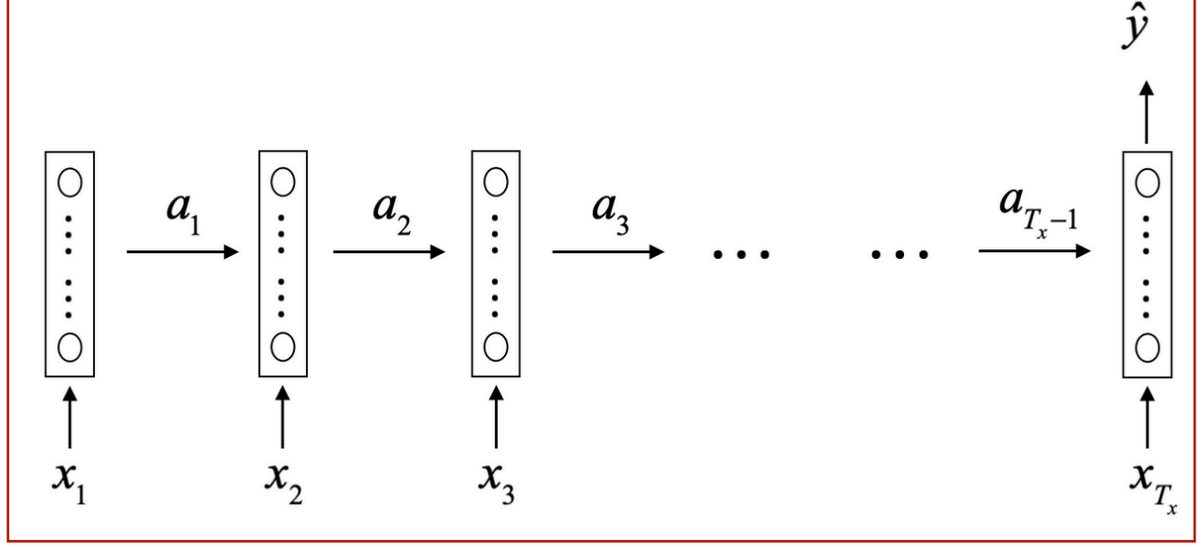

↳ Classification de textes

Architecture 1-N

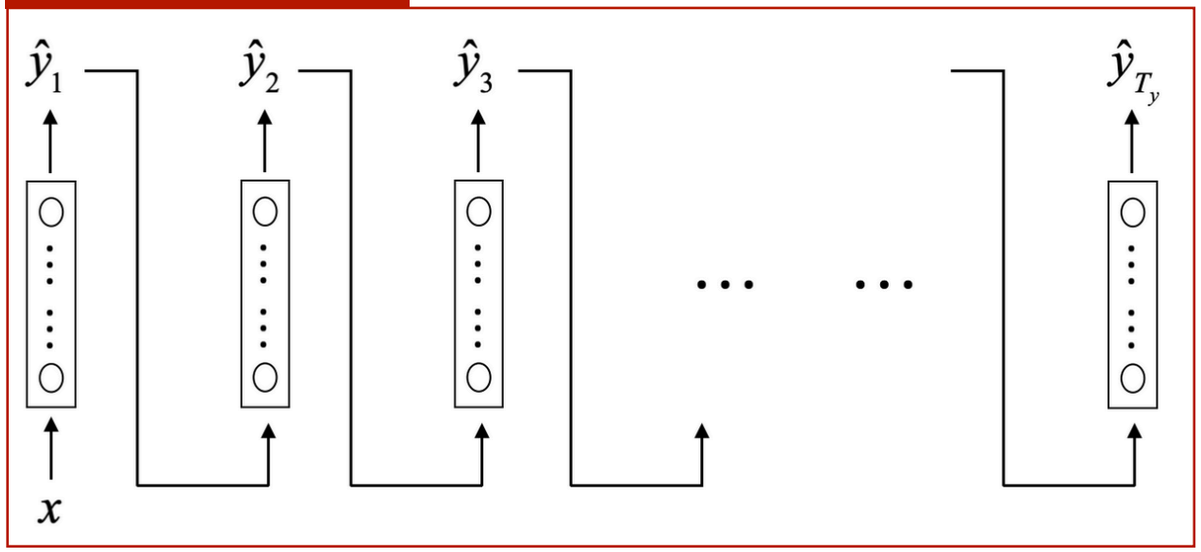

↳ Génération de séquences (textes, musique)

Architecture N-M

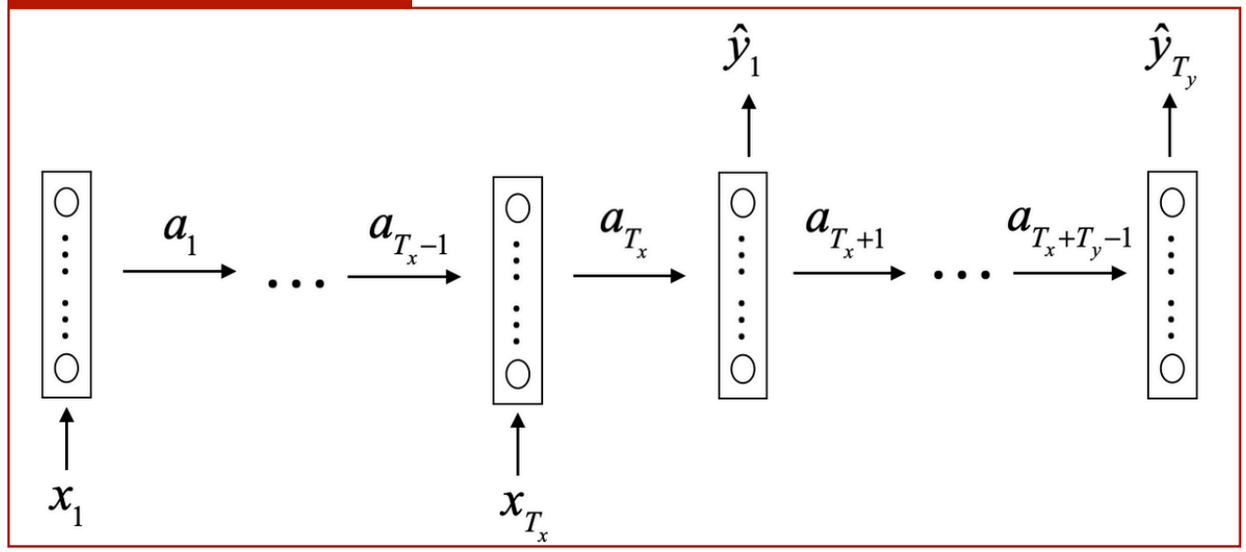

↳ Traducteur automatique

Modèle Bidirectional-RNN (1/2)

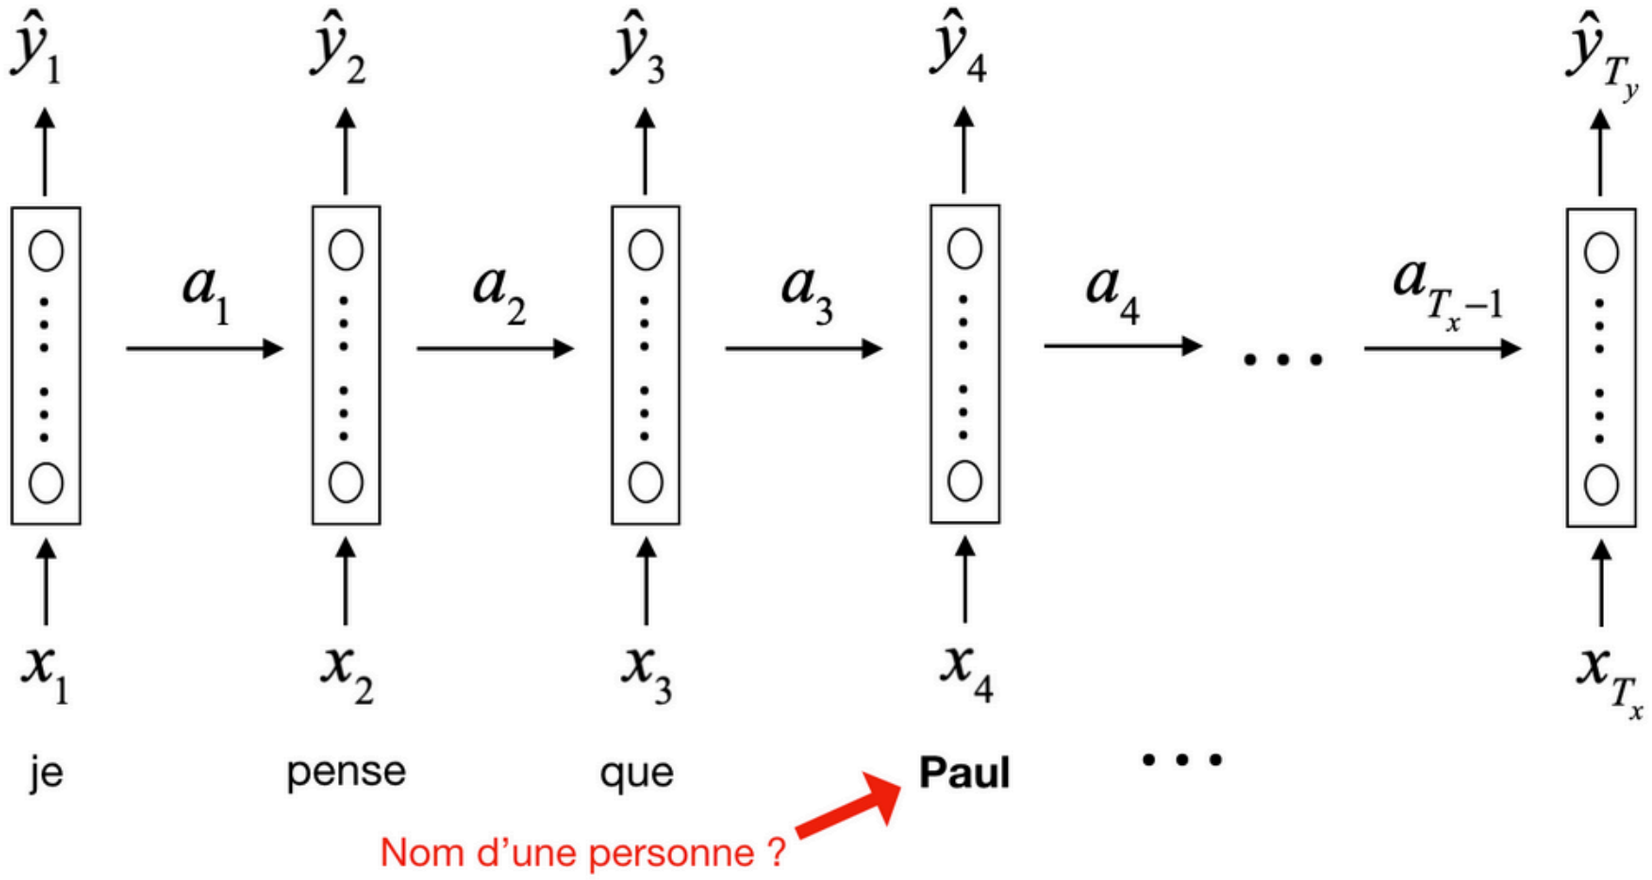

Modèle Bidirectional-RNN (1/2)

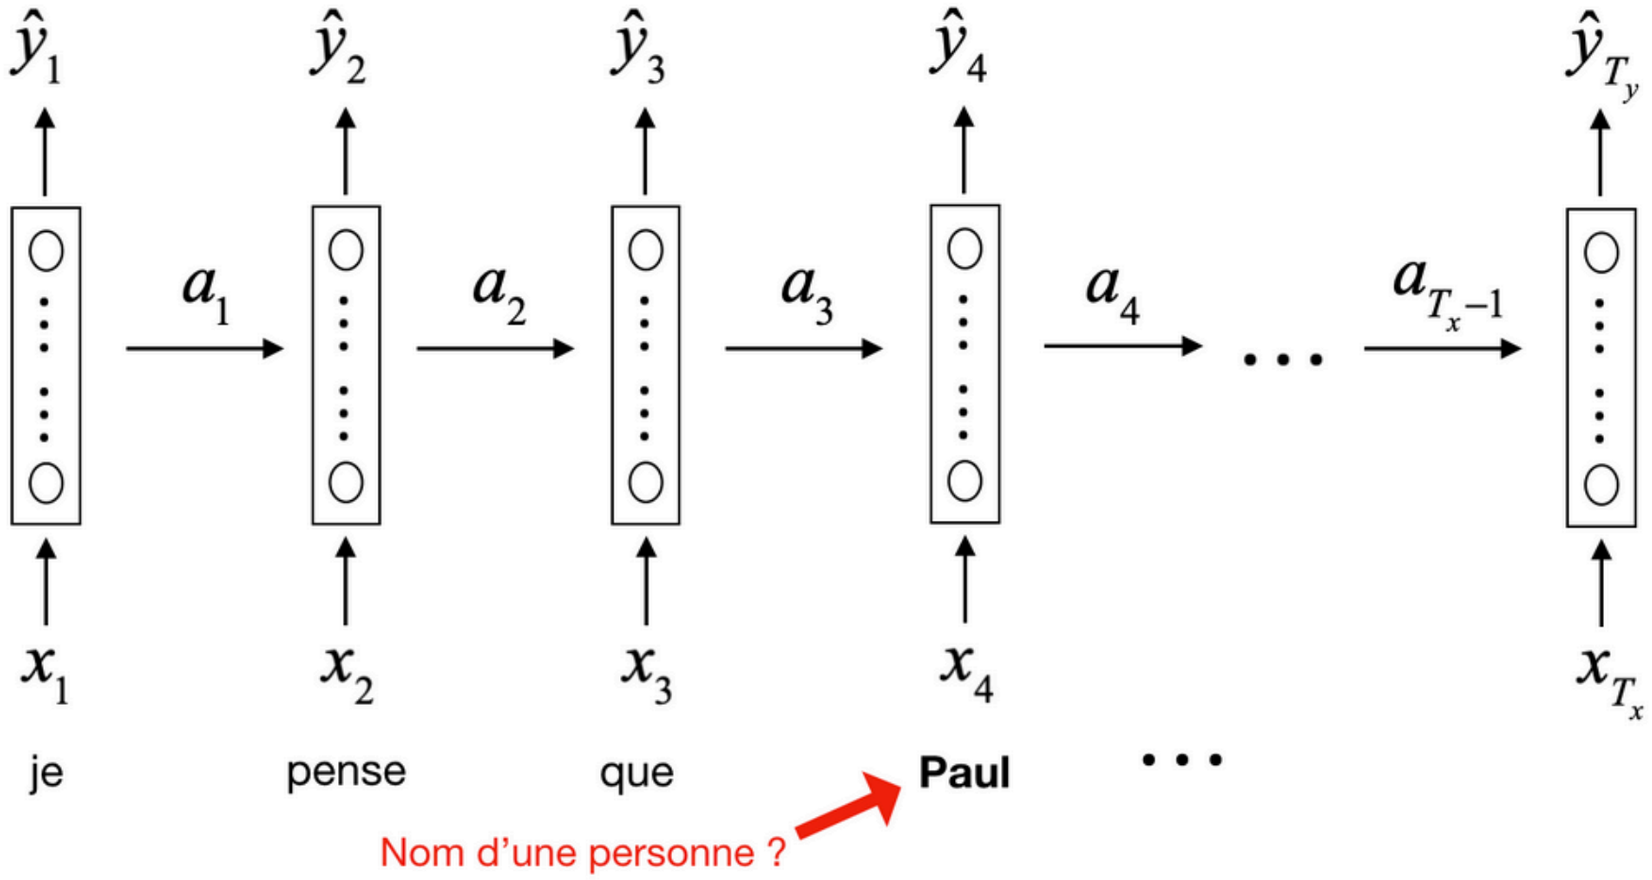

- oui, avec l'exemple : Je pense que **Paul** est né le 10 juillet 1989

Modèle Bidirectional-RNN (1/2)

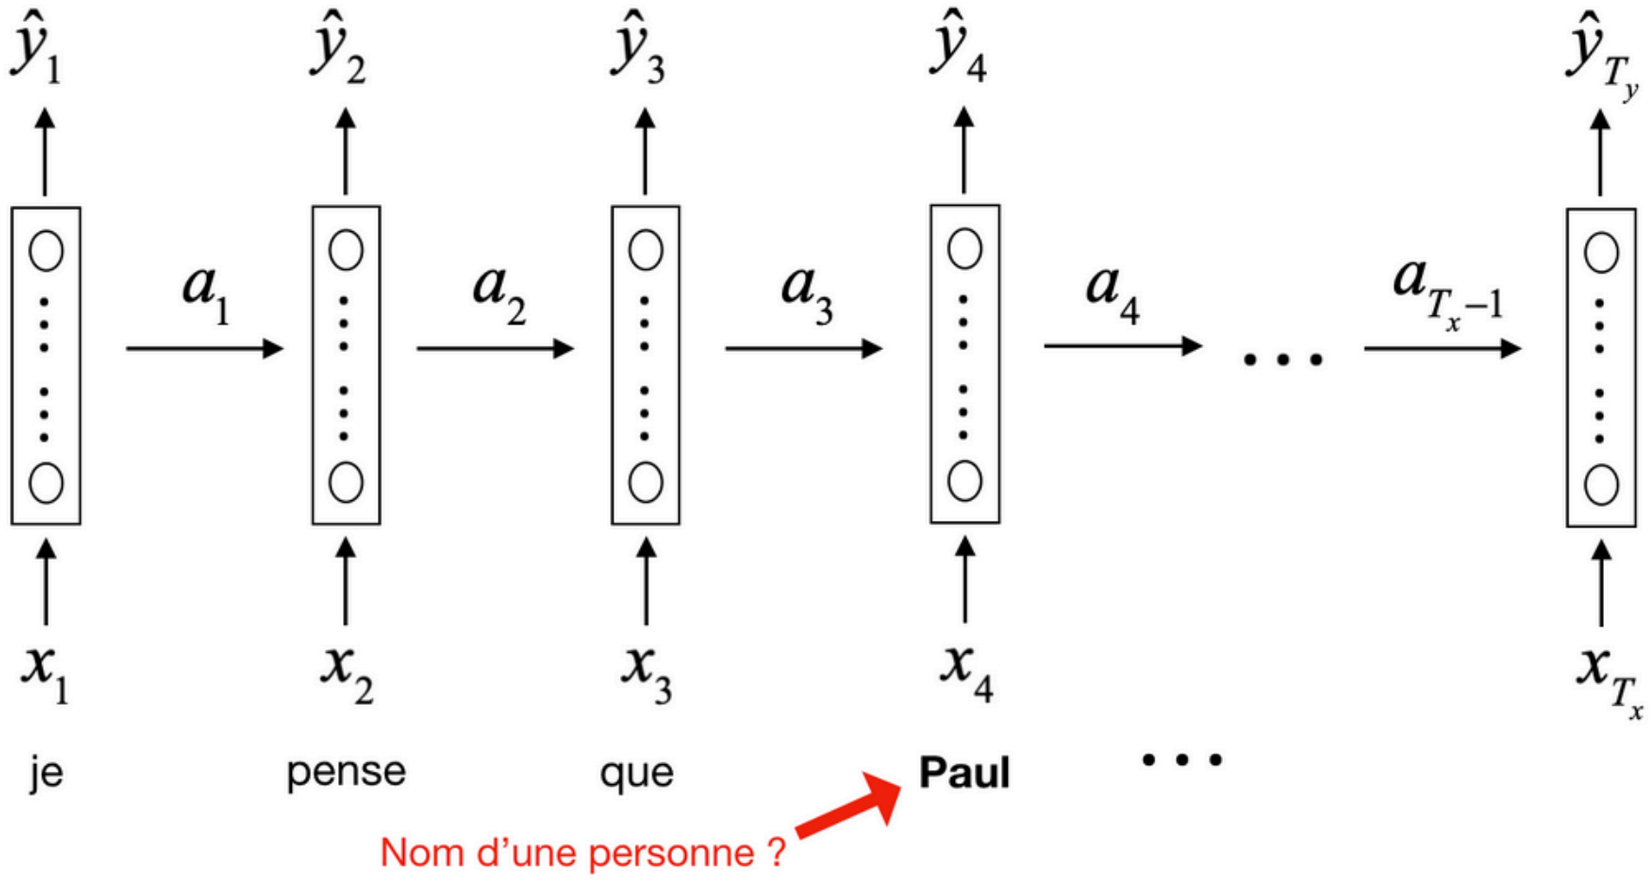

- oui, avec l'exemple : Je pense que **Paul** est né le 10 juillet 1989
- non, avec l'exemple : Je pense que **Paul** est une boulangerie fondée en 1889

Modèle Bidirectional-RNN (1/2)

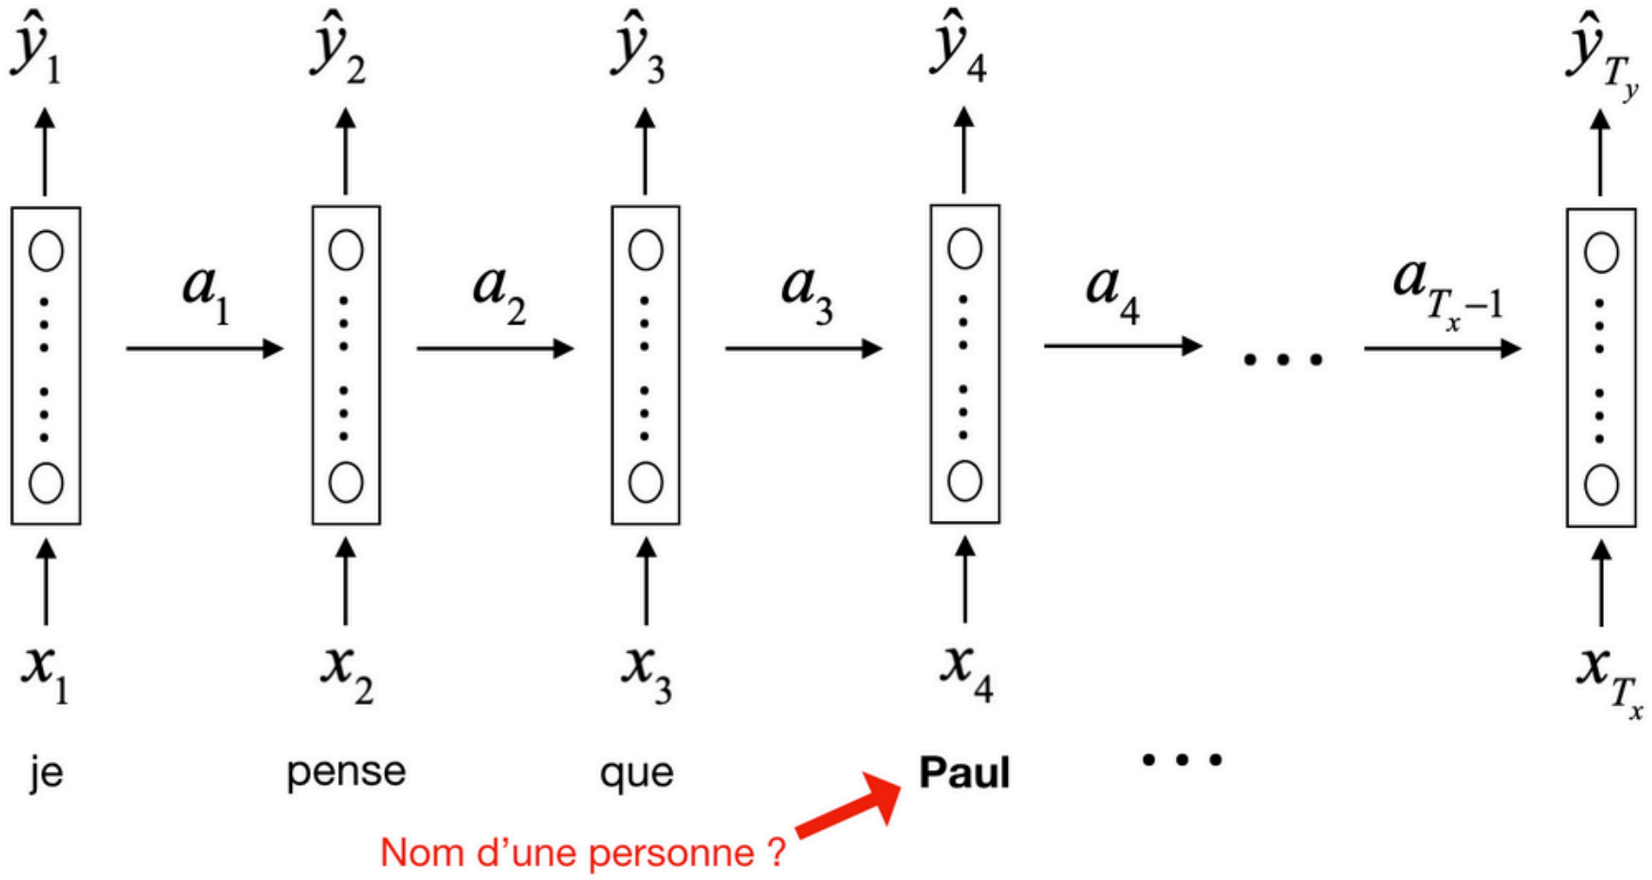

- oui, avec l'exemple : Je pense que **Paul** est né le 10 juillet 1989
- non, avec l'exemple : Je pense que **Paul** est une boulangerie fondée en 1889

Souvent, la prédiction d'une instance doit dépendre des **instances futures**

Modèle Bidirectional-RNN (2/2)

Pour voir l'animation :
https://curiousml.github.io/teaching/DSA/BRNNforward.html

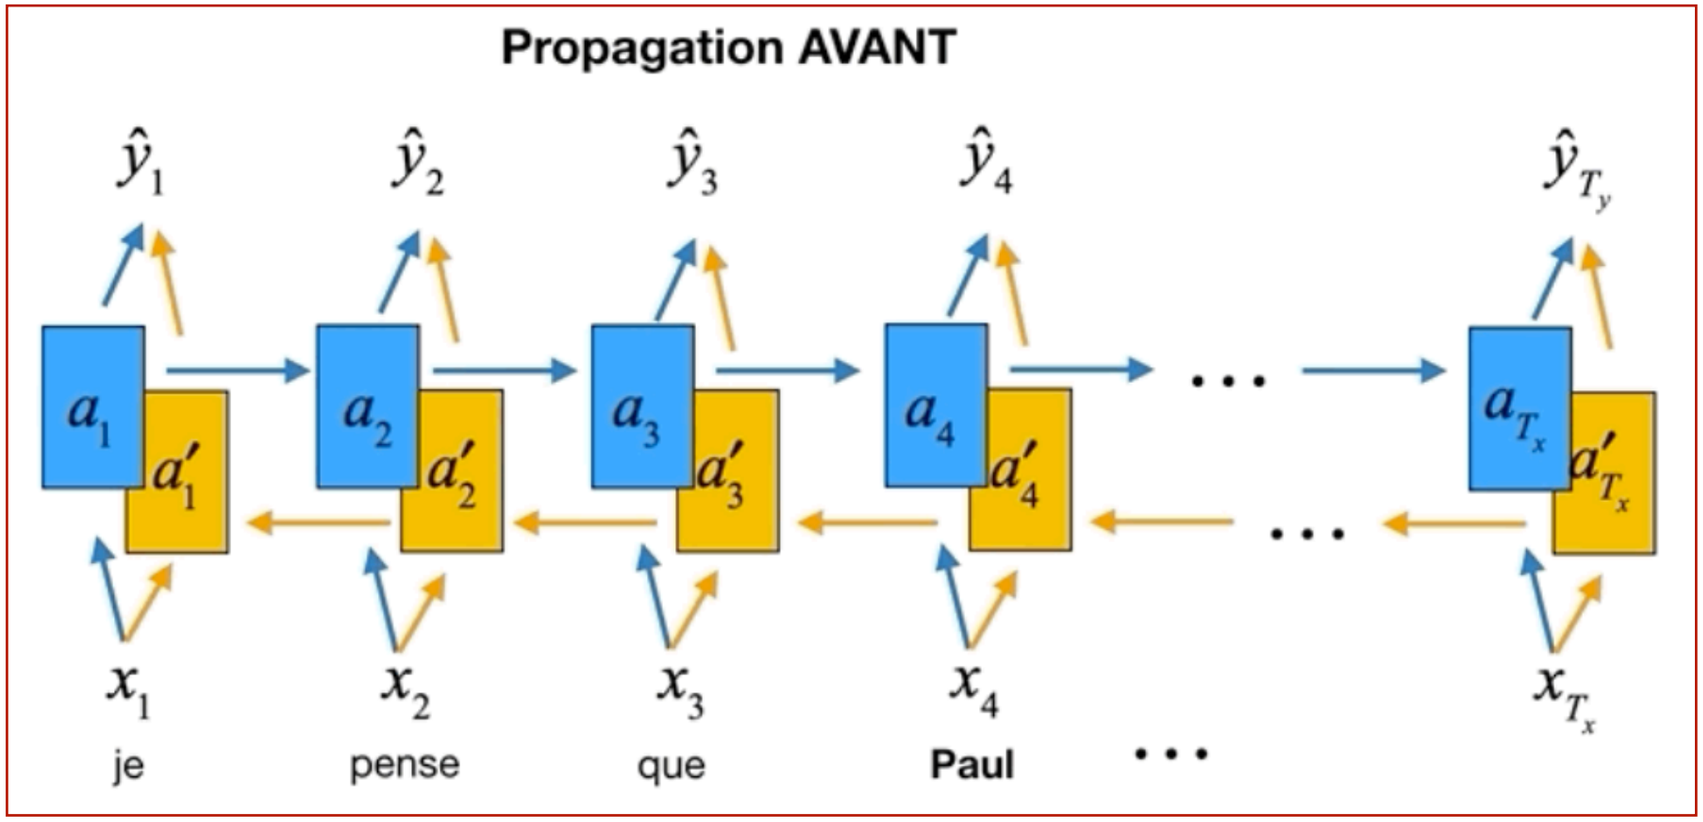

étant donné les poids w_{intput}, w'_{intput}, $w_{transition}$, $w'_{transition}$ et w_{output}, nous **calculons** :

- les activations a_t et les activation a'_t
- puis les prédictions $\hat{y}_t = \sigma(w_{output} \cdot [a_t, a'_t])$ et les fonctions de perte l_t

propagation arrière : mise à jour des poids **par descente de gradient** afin de minimiser les pertes

Modèle deep RNN

DRNN

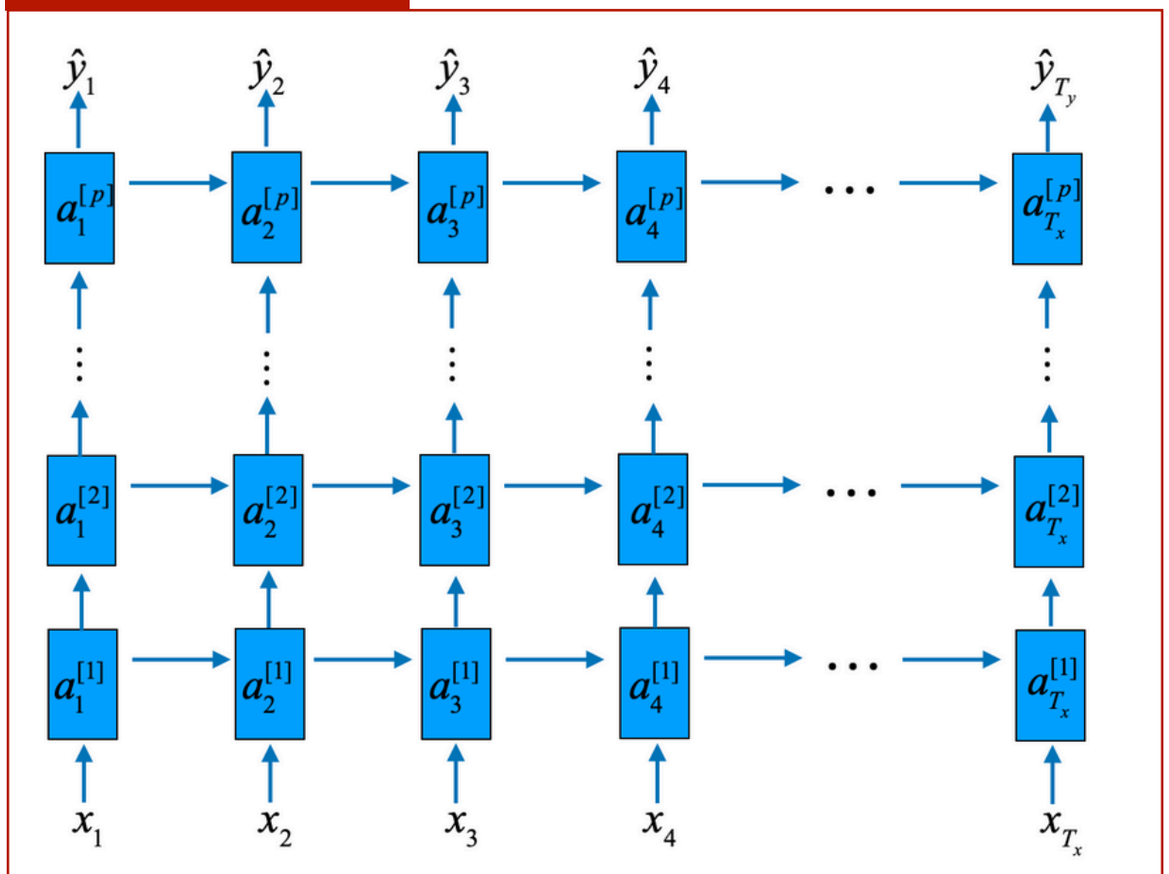

- **Empiler les couches cachées**
- Généralement entre **2 et 4 couches cachées** (car grande complexité de calcul)

Modèle deep RNN

DRNN

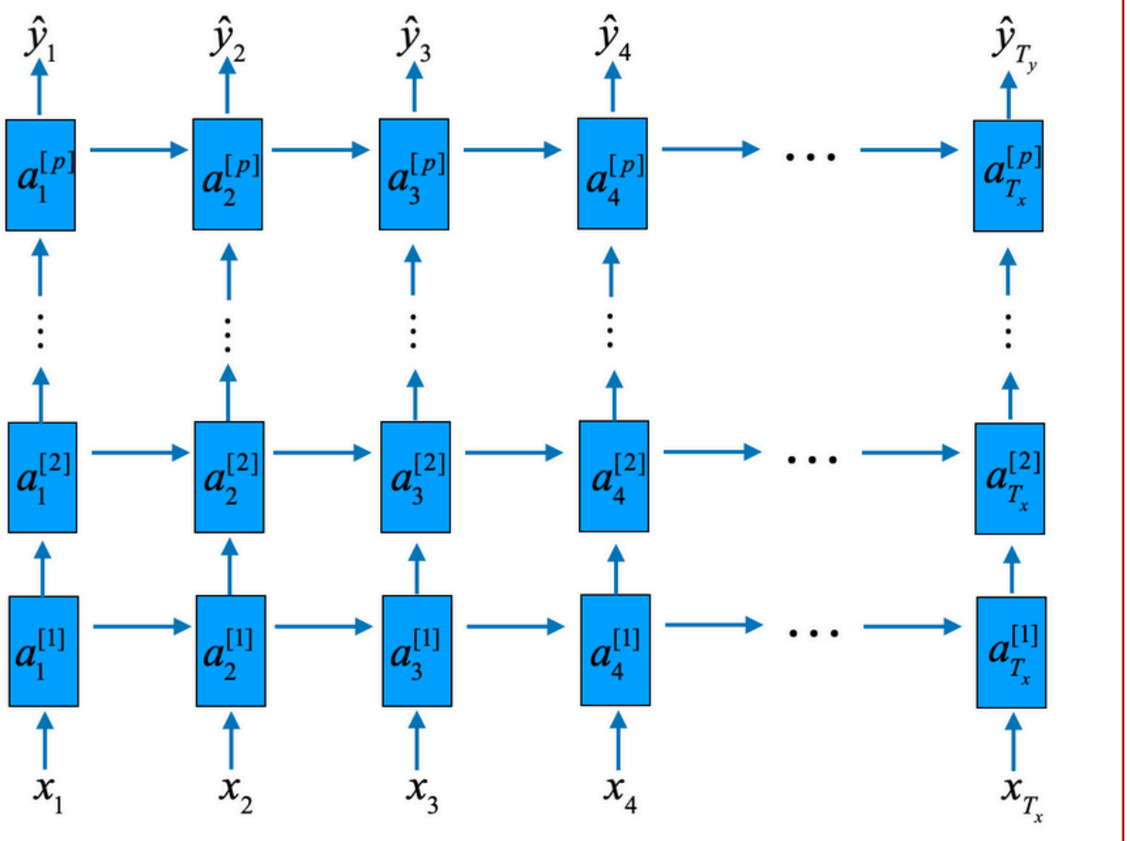

- **Empiler les couches cachées**
- Généralement entre **2 et 4 couches cachées** (car grande complexité de calcul)

DRNN + couches NN supplémentaires

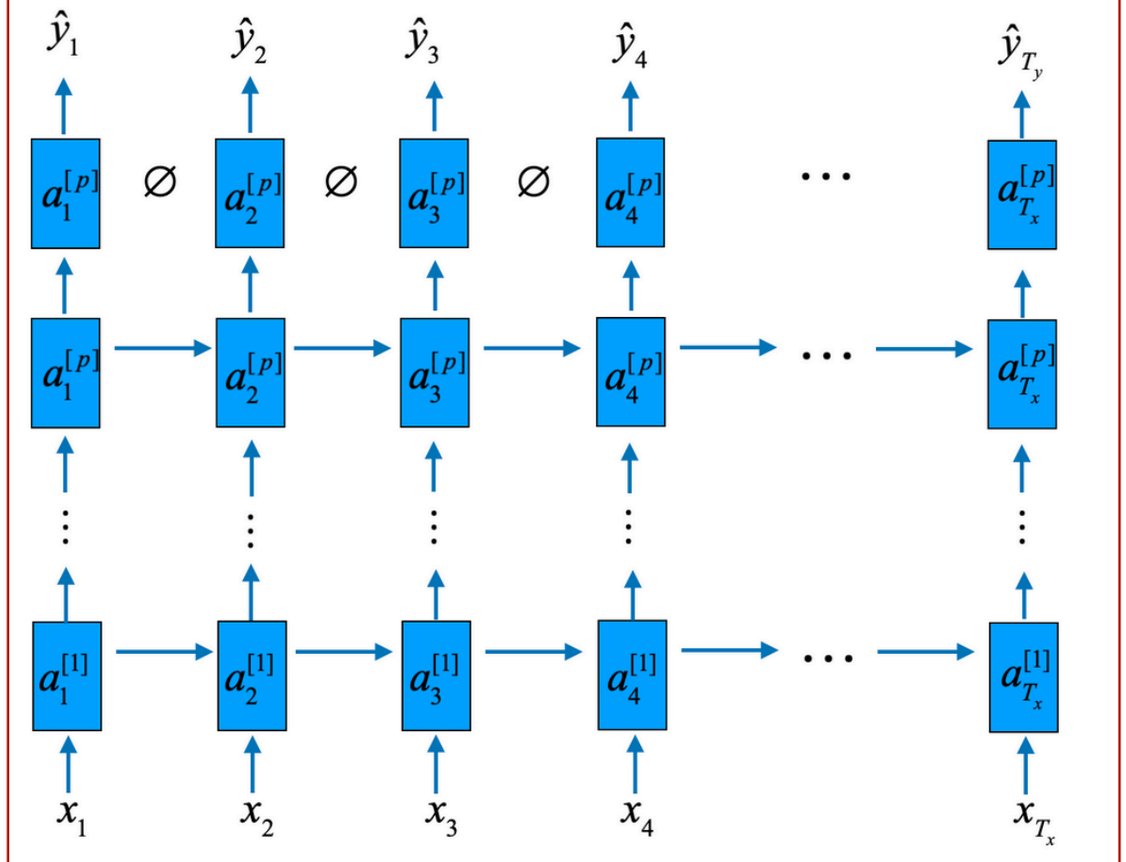

Ces couches supplémentaires n'ont **pas de connections horizontales**

Problème de la disparition du gradient

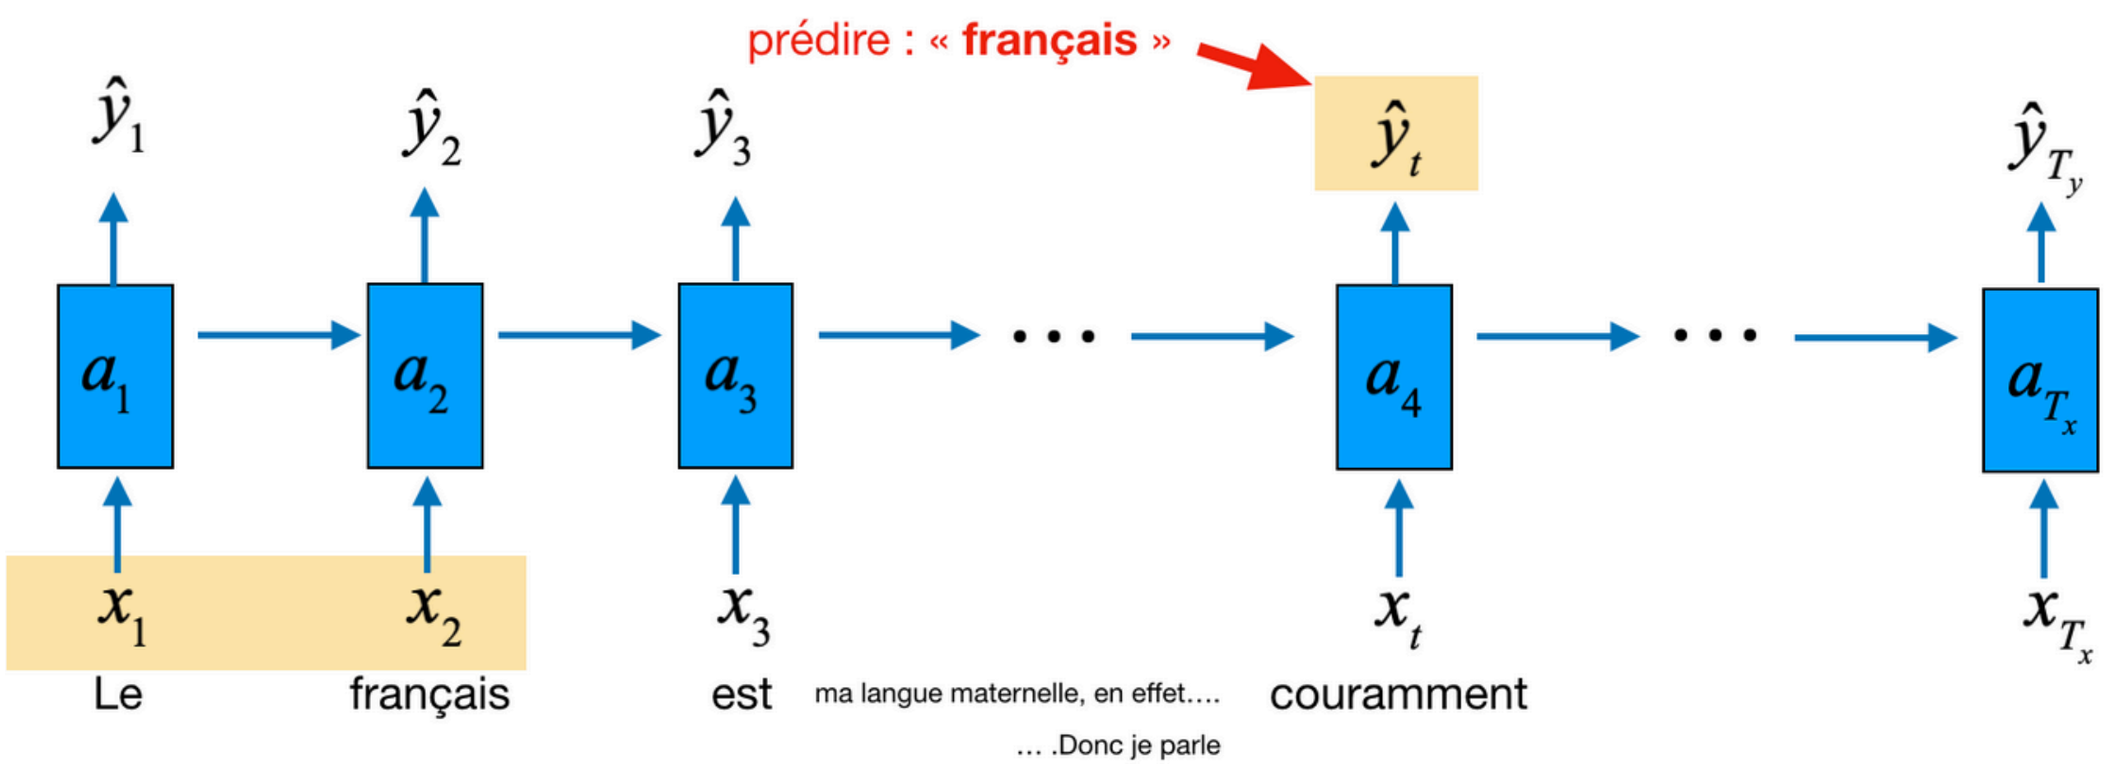

- les RNN classiques ne sont pas très bon pour les **dépendances à long terme** à cause de la disparition du gradient

- **solution :** LSTM / GRU (classique) / BERT (2018) sont **des variantes des RNN**

Résumé

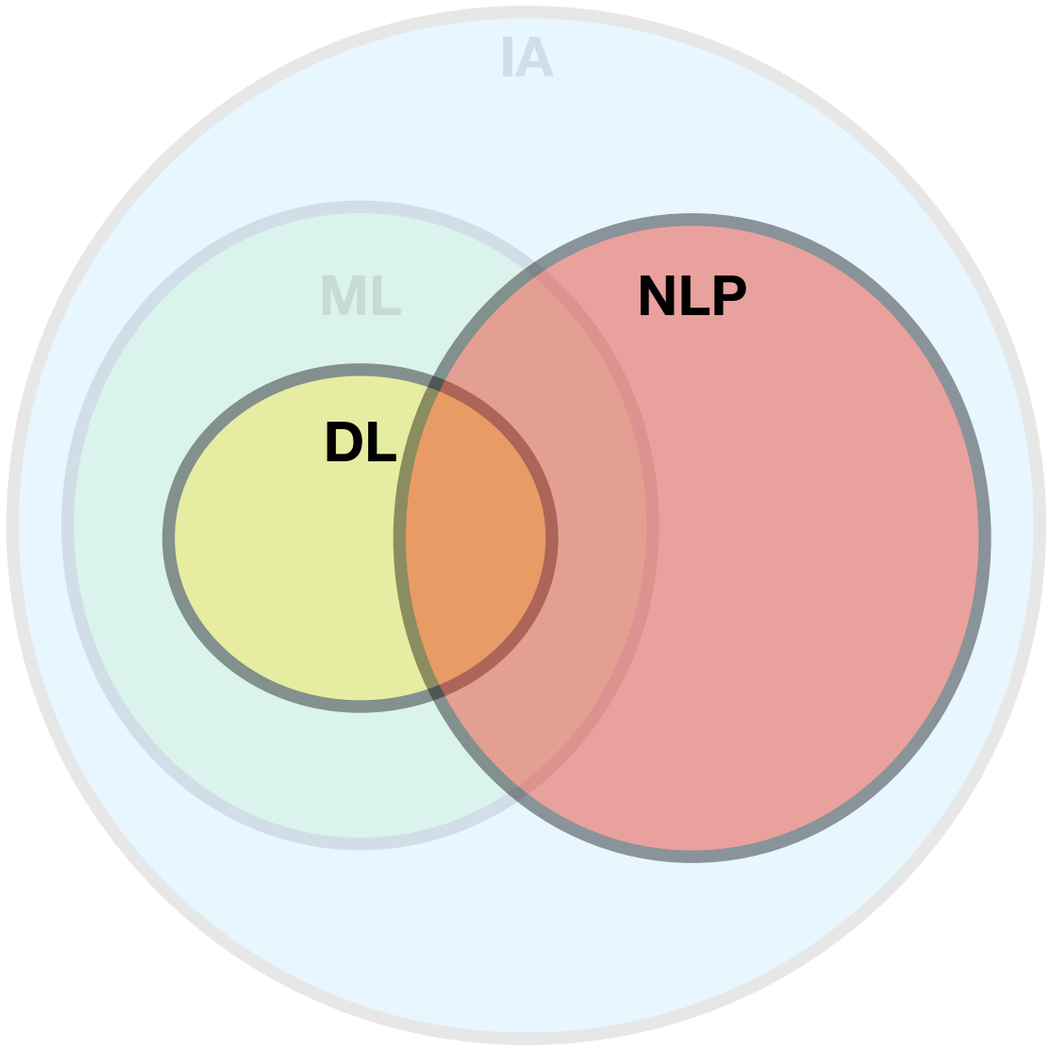

Modèle RNN « classique »

D’autres architectures RNN

Modèles Bidirectional-RNN (BRNN)

Modèle Deep RNN (DRNN)